NMF e LDA: tópicos em textos

Zuil Pirola



UNIVERSIDADE
LUSÓFONA

De textos a palavras

Coleção de documentos representada pelas frequências das palavras

Documento	crime	detetive	amor	viagem
D1	2	1	0	0
D2	0	0	2	1
D3	1	1	0	0

Padrões entre documentos

Documento	crime	detetive	amor	viagem
D1	2	1	0	0
D2	0	0	2	1
D3	1	1	0	0

- D1 e D3 partilham as palavras “crime” e “detetive”.
- D2 tem “amor” e “viagem”.
- Documentos com palavras semelhantes podem estar relacionados.

O conceito de tópico

Um tópico é um **grupo de palavras que tende a aparecer em conjunto** em vários documentos. Ex:

Tokens: crime · detetive · investigar · pistas
Rótulo possível: investigação criminal

As palavras sugerem; não provam

Um tópico não é simplesmente:

- uma palavra frequente;
- uma categoria escrita no documento;
- uma interpretação garantida pelo algoritmo.

É um padrão de palavras **interpretado** no contexto dos documentos.

Precisa interpretar e precisa de contexto!!!!

Um documento, vários tópicos

“Uma detetive investiga um crime enquanto se apaixona durante uma viagem.”

- detetive · investiga · crime → investigação criminal
- apaixona → romance
- viagem → viagem

Relação entre o tamanho do documento e a quantidade de tópicos.

Quando precisamos de métodos

Com poucos documentos, podemos observar padrões manualmente.

Com muitos documentos, precisamos de métodos para:

1. encontrar grupos de palavras que coocorrem;
2. relacionar esses grupos com os documentos;
3. resumir e explorar a coleção.

Matriz documento-termo

Documento	crime	detetive	amor	viagem
D1	2	1	0	0
D2	0	0	2	1
D3	1	1	0	0

Cada linha representa um documento.
Cada coluna representa uma token.
Cada valor indica a frequência da palavra no documento.

X(d,w) = frequência da palavra w no documento d

A matriz formaliza a representação bag of words.

Multiplicação de matrizes

$$(2 \times 3)(3 \times 2) = (2 \times 2)$$

$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \begin{bmatrix} 7 & 8 \\ 9 & 10 \\ 11 & 12 \end{bmatrix} = \begin{bmatrix} 1 \cdot 7 + 2 \cdot 9 + 3 \cdot 11 & 1 \cdot 8 + 2 \cdot 10 + 3 \cdot 12 \\ 4 \cdot 7 + 5 \cdot 9 + 6 \cdot 11 & 4 \cdot 8 + 5 \cdot 10 + 6 \cdot 12 \end{bmatrix} = \begin{bmatrix} 58 & 64 \\ 139 & 154 \end{bmatrix}$$

A fatorização em NMF

Uma matriz grande pode ser aproximada pelo produto de duas matrizes menores.

$$X \approx W H$$

X: matriz documento-termo
W: relação entre documentos e tópicos
H: relação entre tópicos e palavras
K: número de tópicos escolhido

Dimensões e interpretação

$$X_{D \times V} \approx W_{D \times K} H_{K \times V}$$

D = número de documentos
V = tamanho do vocabulário
K = número de tópicos

W: pesos dos tópicos em cada documento
H: pesos das palavras em cada tópico

Interpretar um tópico em NMF

Pesos hipotéticos das palavras no tópico 1 (H):

Palavra	Peso no tópico 1
crime	0,82
detetive	0,74
investigar	0,68
amor	0,05
viagem	0,02

Leitura possível: investigação criminal (Interpretação)

O que influencia a NMF?

- Número de tópicos K (input do pesquisador)
- Representação dos documentos
- Pré-processamento e vocabulário
- Inicialização e aleatoriedade do algoritmo
- Qualidade e dimensão do corpus

Porque considerar LDA?

Um documento pode combinar vários temas.

“Uma história de amor desenvolve-se durante uma investigação criminal numa cidade distante.”

Exemplo de mistura: romance · investigação criminal · viagem

Porque considerar LDA?

"Arts"	"Budgets"	"Children"	"Education"
NEW	MILLION	CHILDREN	SCHOOL
FILM	TAX	WOMEN	STUDENTS
SHOW	PROGRAM	PEOPLE	SCHOOLS
MUSIC	BUDGET	CHILD	EDUCATION
MOVIE	BILLION	YEARS	TEACHERS
PLAY	FEDERAL	FAMILIES	HIGH
MUSICAL	YEAR	WORK	PUBLIC
BEST	SPENDING	PARENTS	TEACHER
ACTOR	NEW	SAYS	BENNETT
FIRST	STATE	FAMILY	MANIGAT
YORK	PLAN	WELFARE	NAMPHY
OPERA	MONEY	MEN	STATE
THEATER	PROGRAMS	PERCENT	PRESIDENT
ACTRESS	GOVERNMENT	CARE	ELEMENTARY
LOVE	CONGRESS	LIFE	HAITI

The William Randolph Hearst Foundation will give $1.25 million to Lincoln Center, Metropolitan Opera Co., New York Philharmonic and Juilliard School. "Our board felt that we had a real opportunity to make a mark on the future of the performing arts with these grants an act every bit as important as our traditional areas of support in health, medical research, education and the social services," Hearst Foundation President Randolph A. Hearst said Monday in announcing the grants. Lincoln Center's share will be $200,000 for its new building, which will house young artists and provide new public facilities. The Metropolitan Opera Co. and New York Philharmonic will receive $400,000 each. The Juilliard School, where music and the performing arts are taught, will get $250,000. The Hearst Foundation, a leading supporter of the Lincoln Center Consolidated Corporate Fund, will make its usual annual $100,000 donation, too.

Figure 8: An example article from the AP corpus. Each color codes a different factor from which the word is putatively generated.

https://dl.acm.org/doi/10.5555/944919.944937

LDA: duas distribuições

Documento → distribuição de tópicos
θd indica os tópicos presentes e a proporção de cada um.

Tópico → distribuição de palavras
ϕk indica que palavras são mais prováveis nesse tópico.

LDA: processo generativo

1. Escolher uma mistura de tópicos para o documento.
2. Para cada palavra, escolher um tópico.
3. Escolher uma palavra associada a esse tópico.
4. Repetir até formar o documento.

Documento → mistura de tópicos → tópico por palavra → palavra

Dirichlet no LDA

LDA usa distribuições de Dirichlet como priors para:

- a mistura de tópicos em cada documento;
- a distribuição de palavras em cada tópico.

Os parâmetros favorecem distribuições mais concentradas ou mais espalhadas.

Saídas do LDA

Tópico → distribuição de palavras
Tópico 1: crime 0,18 · detetive 0,13 · investigar 0,10...

Documento → distribuição de tópicos
Documento 7: tópico 1 — 0,62 · tópico 2 — 0,28 · tópico 3 — 0,10

NMF e LDA

Aspeto	NMF	LDA
Ideia central	Aproximar a matriz por fatores não negativos	Modelar documentos como misturas probabilísticas de tópicos
Documento	Pesos associados aos tópicos	Distribuição de probabilidades sobre tópicos
Tópico	Pesos associados às palavras	Distribuição de probabilidades sobre palavras
Interpretação	Ler padrões nos pesos	Ler padrões nas probabilidades
Número de tópicos	Definido pelo utilizador	Definido pelo utilizador

Validar a interpretação

As palavras de um tópico não se interpretam sozinhas.

- As palavras estão relacionadas entre si?
- Os documentos associados fazem sentido em conjunto?
- O tópico é distinto dos restantes?
- O rótulo é sustentado pelos exemplos?

Escolher o número de tópicos

Não existe um número universal de tópicos.

Considere:

- objetivo da análise;
- dimensão e variedade do corpus;
- coerência e distinção dos tópicos;
- utilidade dos resultados;
- estabilidade entre execuções.

Limites e cuidados

NMF e LDA:

- dependem da representação e do pré-processamento;
- podem produzir tópicos difíceis de interpretar;
- não compreendem o texto como uma pessoa;
- não garantem categorias naturais;
- podem variar com os parâmetros e a aleatoriedade.

Síntese

Bag of words representa documentos pelas palavras e frequências.

Um tópico é um padrão de palavras que tende a aparecer em conjunto.

NMF aproxima a matriz documento-termo por fatores não negativos.

LDA modela documentos como misturas de tópicos e tópicos como distribuições de palavras.

Perguntas de verificação

1. O que representa uma linha e uma coluna da matriz documento-termo?
2. Como inferimos um tópico a partir de bag of words?
3. Como se calcula um elemento do produto de matrizes?
4. Em NMF, o que representam W e H?
5. Como pode um documento participar em vários tópicos no LDA?
6. Porque devemos validar a interpretação de um tópico?